T1, Aprendizado Não Supervisionado

Aprendizado de Máquina

Prof. Me. Otávio Parraga



Em aula, discutimos bastante sobre Aprendizado Supervisionado, onde temos um rótulo que guia o que o modelo deve aprender. Neste trabalho vamos trabalhar com aprendizado não supervisionado, em que o nosso objetivo não é prever um rótulo, mas descobrir estrutura nos dados como grupos, direções de variação, casos atípicos e padrões que aparecem juntos.

Desta forma, para a presente avaliação, iremos realizar uma exploração em cima dos dados fornecidos pela Empresa Regenera. Teremos duas tarefas, ambas obrigatórias, e em cada uma o grupo deverá explorar dois algoritmos diferentes para procurar padrões escondidos nos dados.

Contexto

A Regenera é uma empresa de base tecnológica que trabalha com a biodiversidade química de origem marinha brasileira, com foco na Amazônia Azul, a vasta área marítima sob jurisdição do Brasil. Ela mantém o Banco Regenera, um banco de patrimônio genético que dá acesso legal a microrganismos marinhos para bioprospecção, na busca por moléculas bioativas com aplicação industrial em saúde, cosméticos, alimentos e agricultura. Cada linha do arquivo do dataset deste trabalho é um isolado dessa coleção, ou seja, um microrganismo cultivado a partir de uma amostra ambiental, descrito pela aparência da sua colônia na placa de cultivo e pelo resultado de uma bateria de ensaios funcionais.

Com centenas de dados e vários testes, é difícil enxergar todos os padrões olhando a planilha, e não existe resposta certa guardada em lugar nenhum. Ninguém sabe de antemão quantos perfis distintos existem, nem como as atividades se relacionam. Essas são as perguntas das tarefas a seguir, e respondê-las têm valor prático para quem cuida do banco, já que permite priorizar os isolados que seguem para as etapas caras de caracterização química e evitar ensaios redundantes.

Dataset

Nosso dataset possui 506 instâncias, e podem carregá-lo como um `DataFrame` do `pandas`.

```
import pandas as pd
df = pd.read_csv("Data_REG.tsv", sep="\t")
```

As colunas se organizam em quatro grupos.

Grupo	Colunas	Descrição
Identificação	`n°`	Código Identificador
Tipo celular	`GRAM`	Resultado da coloração de Gram ou identificação como levedura (`Negativo` , `Positivo` , `Levedura`)
Morfologia da colônia	`Cor` , `Cores` , `Borda` , `Textura` , `Forma` , `Brilho` , `Muco` , `Relevo`	Características visuais da colônia, registradas como códigos. Algumas células contêm mais de um código, como `2 & 1`
Atividades	`Atividade 01` a `Atividade 23`	Resultados dos ensaios funcionais. Há colunas binárias (`Positivo` / `Negativo` ou `0` / `1`), ordinais e contínuas

Pontos de atenção.

- Os nomes dos ensaios foram anonimizados. Parte do trabalho é descobrir, a partir dos próprios dados, como as atividades se relacionam.
- Os códigos da morfologia são rótulos, não quantidades. `Cor = 2` não é "o dobro" de `Cor = 1` .
- O arquivo vem de uma planilha real de laboratório e contém problemas de qualidade. Encontrá-los e tratá-los faz parte da avaliação.

Estrutura do Trabalho

O trabalho tem três etapas, todas obrigatórias.

1. Etapa de Pré-Processamento dos Dados.
2. Etapa de Análise dos Dados, com as duas tarefas abaixo.
3. Etapa de Análise Crítica e Conclusões.

Tarefa	Descrição da tarefa	Algoritmos disponíveis
A - Agrupamento	Particionar os isolados em grupos de perfil semelhante, escolher o número de grupos e caracterizar cada um deles.	K-Means, K-Medoids, Hierárquico, DBSCAN, HDBSCAN, Mistura de Gaussianas, Espectral, K-Prototypes

Tarefa	Descrição da tarefa	Algoritmos disponíveis
B - Redução de Dimensionalidade	Resumir os 23 ensaios em poucas dimensões e projetar os isolados em duas dimensões para visualizar a coleção.	PCA, SVD truncada, MCA, MDS, Isomap, t-SNE, UMAP

Em cada tarefa o grupo deve escolher e aplicar dois algoritmos diferentes e compará-los.

Pré-Processamento dos Dados

Passo 1. Exploração dos Dados

Antes de transformar qualquer coisa, entenda o que existe no arquivo. Levante o tipo de cada coluna, que pode ser nominal, ordinal, binária ou contínua. Em seguida, examine as distribuições das colunas, a quantidade de valores ausentes e as relações entre as variáveis, tanto entre as atividades quanto entre a morfologia e o `GRAM`. Histogramas, contagens, tabelas de contingência e mapas de calor de correlação são recursos úteis aqui, e cabe ao grupo decidir quais usar e como.

Para cada gráfico, descreva o que ele mostra.

Passo 2. Limpeza

O arquivo vem de uma planilha real de laboratório e contém problemas de qualidade. Procure-os e os trate. Alguns exemplos do que costuma aparecer são grafias diferentes para a mesma categoria, células com mais de um valor, resíduos de fórmula herdados da planilha, identificadores repetidos e valores fora do esperado para a coluna. Registre o que encontrar e aponte qual o tratamento usado para corrigir.

Nenhum desses casos tem uma única solução correta. O que será avaliado é se a decisão foi consciente, justificada e aplicada de forma consistente.

Passo 3. Transformações

Decida quais transformações serão aplicadas nos dados e justifique-as, por exemplo.

- Codificação das variáveis categóricas, como *one-hot*, codificação ordinal ou codificação binária.
- Transformação de colunas assimétricas ou de cauda longa, por exemplo com logaritmo ou raiz.

- Colocação das colunas numéricas em escala comparável, por exemplo com padronização ou normalização.
- Tratamento dos valores ausentes, por imputação ou por remoção.
- Alguma coluna será removida?
- Dentre outras possíveis...

Análise dos Dados

Esta etapa tem duas tarefas, e ambas são obrigatórias. Em cada uma, o grupo escolhe dois algoritmos da lista correspondente, aplica os dois e compara o que cada um mostra. A ideia não é acumular métodos, e sim entender por que dois algoritmos que olham os mesmos dados chegam a respostas diferentes.

Para cada algoritmo escolhido, o relatório deve explicar como o método funciona e quais premissas ele assume sobre os dados, por exemplo o formato esperado dos grupos, a medida de distância adotada, a necessidade de definir o número de grupos ou a suposição de que as relações são lineares. Boa parte da diferença entre os resultados vem dessas premissas, e a comparação entre dois algoritmos só faz sentido quando elas estão explícitas.

A Tarefa A será agrupamento, e a Tarefa B será Redução de Dimensionalidade. Neste caso, a redução vai permitir que consigamos agrupar os dados e visualizá-los em um espaço humanamente compreensível.

Tarefa A, Agrupamento

O que queremos aqui é descobrir se existem grupos no conjunto de dados, e se sim, quais são eles!

Algoritmos sugeridos

Algoritmo	Ideia central	Pontos de atenção
K-Means	Escolhe *k* centros e atribui cada isolado ao centro mais próximo, recalculando os centros até estabilizar.	Exige definir *k*, favorece grupos arredondados e de tamanho parecido, e é sensível a valores extremos.
K-Medoids	Mesma lógica do K-Means, porém o representante de cada grupo é um isolado real e não uma média.	Mais robusto a valores extremos e aceita outras medidas de distância, mas é mais lento.

Algoritmo	Ideia central	Pontos de atenção
Agrupamento Hierárquico Aglomerativo	Começa com cada isolado sozinho e vai unindo os pares mais próximos, produzindo um dendrograma com a estrutura em todos os níveis.	Não exige *k* de antemão, mas exige escolher o critério de ligação, como *ward*, média ou completa.
DBSCAN	Forma grupos a partir de regiões densas e deixa fora, como ruído, os isolados que não pertencem a nenhuma delas.	Encontra grupos de formato irregular e identifica ruído, porém depende de `eps` e `min_samples` e perde força em muitas dimensões.
HDBSCAN	Versão hierárquica do DBSCAN, que dispensa a escolha de `eps` e lida com grupos de densidades diferentes.	Tem menos hiperparâmetros, mas o resultado é mais difícil de explicar.
Mistura de Gaussianas	Descreve os dados como uma soma de gaussianas e informa a probabilidade de cada isolado pertencer a cada componente.	Aceita grupos alongados e fronteiras suaves, porém supõe uma forma para os dados e exige definir o número de componentes.
Agrupamento Espectral	Constrói um grafo de similaridade entre os isolados e agrupa a partir da estrutura desse grafo.	Captura grupos não convexos, mas é caro e exige definir o número de grupos.
K-Prototypes	Variante do K-Means que trata colunas numéricas e categóricas ao mesmo tempo.	Permite analisar morfologia e atividades juntas. Está na biblioteca `kmodes`.

Escolha dois algoritmos de naturezas diferentes. Uma combinação recomendada é um método baseado em centros, como o K-Means, junto de um método hierárquico ou baseado em densidade, como o Agrupamento Hierárquico ou o DBSCAN, porque as suposições dos dois são distintas e a comparação fica informativa. Utilizar k-Means e k-Medoids, por exemplo, levará a uma penalização da nota.

O que fazer

1. Escolha dois algoritmos.
2. Defina os hiperparâmetros. Para os métodos que exigem *k*, varie *k* de 2 a 10 e apresente o método do cotovelo e a silhueta média. Para o DBSCAN, justifique `eps` e `min_samples` com o gráfico de *k*-distâncias. Para a Mistura de Gaussianas, use BIC ou AIC.
3. Aplique os dois algoritmos sobre os dados já pré-processados.

4. Caracterize cada grupo encontrado pelo tamanho, pelo perfil médio das atividades, e pela moda das variáveis de morfologia. Dê um nome descritivo a cada grupo, como "espécies com alta resposta nas atividades 09 a 12".
5. Compare as duas partições entre si e discuta onde os algoritmos discordam e por quê.
6. Se preferir, o agrupamento também pode ser feito sobre os dados já reduzidos pela Tarefa B, em vez de sobre os atributos originais. Nesse caso, explique por que essa escolha foi feita e o que ela muda no resultado.

Como avaliar

A avaliação de Clustering é sempre complicada, uma vez que não temos rótulo para dizer se o grupo encontrado é consistente ou não. O que podemos fazer, do lado de Machine Learning, é usar métricas estatísticas para nos dizer o quão coerente é o agrupamento encontrado. Use pelo menos duas métricas internas, uma métrica externa e o teste de estabilidade.

Métricas internas

- Silhueta
- Índice de Davies-Bouldin
- Índice de Calinski-Harabasz
- Índice de Dunn
- Inércia
- Estabilidade

Métricas externas

- Índice de Rand Ajustado (ARI)
- Informação Mútua Normalizada (NMI ou AMI)
- Homogeneidade, completude e V-measure
- Classificador

A silhueta de uma instância *i* é definida abaixo.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}}$$

onde $a(i)$ é a distância média de *i* aos membros do próprio grupo e $b(i)$ é a distância média de *i* aos membros do grupo vizinho mais próximo.

Duas ressalvas importantes. A primeira é que as métricas internas premiam grupos compactos e arredondados, o que favorece naturalmente o K-Means. Então elas não podem ser o único critério quando um dos algoritmos aceita formatos irregulares, como o DBSCAN. A segunda é

que um valor externo baixo não significa que o agrupamento está errado, já que os isolados podem estar se organizando por um critério que não é o tipo celular.

Tarefa B, Redução de Dimensionalidade

Para visualizar os grupos encontrados, idealmente, podemos utilizar um algoritmo de redução de dimensionalidade e logo após plotar as duas dimensões encontradas. Cada método de redução aplica uma ideia diferente.

Algoritmo	**Ideia central**	**Pontos de atenção**
PCA	Encontra combinações lineares das colunas que concentram a maior variância possível, em ordem decrescente.	Os eixos são interpretáveis pelos pesos e os dados podem ser reconstruídos. Só captura relações lineares.
SVD truncada	Fatoração equivalente à PCA, mas que dispensa centrar a matriz.	Útil em matrizes esparsas, como as que o *one-hot* costuma gerar.
MCA	Equivalente à PCA para variáveis categóricas.	É a opção natural para as variáveis de morfologia. Está na biblioteca `prince`.
MDS	Procura uma configuração em poucas dimensões que preserve as distâncias entre os pares de isolados.	Preserva bem a estrutura global, porém é caro e os eixos não têm interpretação.
Isomap	Como o MDS, mas medindo a distância ao longo do grafo de vizinhança em vez de em linha reta.	Recupera estruturas curvas. Depende do número de vizinhos.
t-SNE	Método não linear que preserva a vizinhança local de cada ponto.	Mostra bem grupos locais, porém a distância entre grupos afastados e o tamanho aparente deles não são confiáveis. Depende de `perplexity`.
UMAP	Semelhante ao t-SNE, mais rápido e com melhor preservação da estrutura global.	Depende de `n_neighbors` e `min_dist`, e a figura muda bastante com eles.
Autoencoder	Rede neural que aprende a comprimir os dados em poucas dimensões e a reconstruí-los a partir delas.	Captura relações não lineares complexas e permite reconstrução, porém exige mais ajuste e não entrega eixos interpretáveis.

Escolha duas estratégias, sendo pelo menos uma linear, como PCA ou MCA, e pelo menos uma não linear, como t-SNE, UMAP, Isomap, MDS ou Autoencoder. A linear entrega eixos interpretáveis e a não linear costuma separar melhor os grupos na figura, e é justamente o contraste entre as duas que interessa.

O que fazer

1. Escolha as duas estratégias e justifique a escolha.
2. Projete os dados em duas dimensões com cada uma e apresente as figuras lado a lado.
3. Pinte os pontos usando os agrupamentos descobertos nas duas abordagens da tarefa acima.
4. Compare as duas projeções. Elas contam a mesma história sobre a coleção?

Como avaliar

Diferente do agrupamento, aqui existem métricas que medem de forma bastante direta o quanto a projeção preservou a informação original.

- Variância explicada, por componente e acumulada, para as estratégias lineares. Mostra quanta informação cada eixo carrega.
- Erro de reconstrução, também para as lineares e para o Autoencoder. Projete os dados em *d* dimensões, reconstrua-os e calcule o erro quadrático médio, apresentando a curva do erro em função de *d*.
- `trustworthiness`, para as duas projeções. Vai de 0 a 1 e indica se os pontos vizinhos na figura também eram vizinhos no espaço original.
- Estabilidade da figura, rodando a projeção com sementes diferentes e variando o hiperparâmetro principal, como `perplexity` no t-SNE ou `n_neighbors` no UMAP.
- Utilidade da redução, medida com um classificador, conforme descrito abaixo.

$$\mathrm{MSE}(d) = \frac{1}{n\,p} \sum_{i=1}^{n} \left\| x_i - \hat{x}_i^{(d)} \right\|^2$$

onde *n* é o número de instâncias, *p* o número de atributos e $\hat{x}_i^{(d)}$ a reconstrução da instância *i* a partir de *d* dimensões.

Etapa de Análise Crítica e Conclusões

1. Quais os achados de cada etapa?
2. Sensibilidade ao pré-processamento. Refaça a análise principal de pelo menos uma das duas tarefas alterando pelo menos uma decisão da Etapa de Pré-Processamento, por

exemplo: com e sem log, com outra escala ou com outra forma de tratar as células com dois códigos, e compare os resultados. Quais decisões mais afetaram as conclusões?
3. Limitações. O que os dados e os métodos não permitem afirmar?

Entrega

- Número de Integrantes de 2 a 5.
  - Atenção. Trabalhos individuais **NÃO SERÃO CONSIDERADOS!**
- Data de Entrega em **24/11**.
- Formato da Entrega com arquivos ou link no Moodle mais apresentação em sala de aula.
  - A apresentação será feita diretamente ao professor, sem necessidade de slides formais. O foco é a discussão da metodologia e dos resultados, e não a qualidade visual.

Entregáveis

- `README.md` contendo nome e matrícula de todos os integrantes, algoritmos escolhidos em cada tarefa e instruções passo a passo para instalar as dependências e reproduzir os resultados, com as sementes aleatórias fixadas.
- Código-fonte completo (notebook ou link para repositório GitHub).
- Relatório em PDF ou PPT contemplando os itens abaixo.
  1. Referencial Teórico com a descrição das técnicas e métricas de avaliação utilizadas, acompanhada de referências bibliográficas.
  2. Delimitação do Desenvolvimento, indicando o que foi reaproveitado de código de repositórios públicos e o que foi implementado pelo grupo. Deixe essa distinção clara.
  3. Processamento de Dados com as decisões tomadas em cada passo e suas justificativas.
  4. Metodologia das Tarefas com métodos aplicados, parâmetros e estratégia de avaliação.
  5. Resultados e Análise com métricas, figuras comentadas e interpretação.
  6. Conclusão, Limitações e Dificuldades, incluindo a Análise Crítica acima.
  7. Referências.

Critérios de Avaliação

Aspecto	**Pontos**
Exploração e Limpeza	1,5
Pré-Processamento e Representação	1,5
Aplicação dos Métodos	2,0
Avaliação dos Resultados	2,0

Aspecto	Pontos
Interpretação e Análise Crítica	2,0
Relatório e Apresentação	1,0
Total	10,0

Bibliotecas Sugeridas

Principais bibliotecas.

- Scikit-learn para K-Means, Agrupamento Hierárquico, DBSCAN, HDBSCAN, Mistura de Gaussianas, Agrupamento Espectral, PCA, MDS, Isomap, t-SNE e métricas de avaliação.
- Pandas
- NumPy
- SciPy para dendrogramas em `scipy.cluster.hierarchy`.
- Matplotlib
- Seaborn
- UMAP

Bibliotecas opcionais.

- kmodes para K-Prototypes.
- prince para MCA.
- scikit-learn-extra para K-Medoids.